Gabriel Chaves

Engenheiro de Software | IA e LLMs

Cubatão, SP (Remoto) · +55 (11) 94614-0288 · gabriel.chaves.tech@gmail.com
linkedin.com/in/gabriel-chv · github.com/gabrielchv

RESUMO PROFISSIONAL

Engenheiro de Software com mais de 3 anos entregando aplicações web em produção, hoje focado em engenharia de IA. Desenvolvo funcionalidades com **LLMs** de ponta a ponta — assistente de e-mail integrado à API do Gmail, com categorização automática e respostas em **streaming** em tempo real, e um orquestrador de tarefas por voz rodando em container no **Google Cloud Run**. Atuo em toda a stack: TypeScript e React no frontend, Python e Node.js no backend, Google Cloud Platform no deploy. Inglês fluente e três anos trabalhando com times internacionais, em modelos híbrido e 100% remoto.

EXPERIÊNCIA PROFISSIONAL

Engenheiro de Software (Freelance) — Autônomo
Jul 2026 – Atual · Remoto

- Reconstruindo o site institucional da **Yank EPC**, empresa de engenharia, suprimentos e construção, em **Next.js** — com visibilidade em buscadores, compatibilidade mobile e experiência do usuário como requisitos centrais.
- Aplicando **renderização no servidor** e uma arquitetura de páginas estruturada para tornar o conteúdo de serviços e projetos indexável, com marcação semântica e metadados por rota.
- Reconstruí a interface **mobile-first** mirando os **Core Web Vitals**: estabilidade de layout, imagens responsivas e prontidão de interação em diferentes tamanhos de tela.
- Conduzindo sessões de levantamento de requisitos diretamente com o cliente para definir o conteúdo de produtos e serviços, em vez de construir sobre uma especificação pronta.

Engenheiro de Software / IA (Freelance) — Meet Oscar
Fev 2025 – Nov 2025 · Remoto · app.meetoscar.com

- Desenvolvi um assistente de e-mail com IA integrando a **API do Gmail** a modelos **Gemini** e **OpenAI**, com categorização automática de mensagens e respostas em **streaming** em tempo real numa interface React própria.
- Liderei a reescrita completa da plataforma legada em HTML/JS para **React** e **Tailwind CSS**, melhorando os Core Web Vitals e a experiência de desenvolvimento.
- Estabeleci a base de engenharia de frontend de uma startup sem especialista na área: padrões de componentes, estrutura de diretórios e biblioteca acessível de componentes do Figma ao React.

Desenvolvedor de Software Júnior — Trular
Set 2022 – Dez 2024 · São Paulo, SP · Híbrido

- Liderei a migração do motor principal de imóveis de **Next.js** para **SvelteKit**, otimizando a renderização no servidor e melhorando a visibilidade orgânica em buscadores.
- Construí **crawlers em Python** (**Scrapy**, BeautifulSoup) em instâncias cloud para agregar dados de anúncios em tempo real de múltiplas fontes, alimentando o banco central do produto com alta disponibilidade e consistência.
- Entreguei funcionalidades mobile multiplataforma com **React Native** e Expo, incluindo integrações nativas de biometria e câmera no Android.
- Implantei a cultura de testes: testes unitários com Vitest, documentação de componentes no Storybook e cobertura ponta a ponta com **Playwright**.
- Colaborei diariamente em inglês e espanhol com stakeholders internacionais em revisões de arquitetura e planejamento técnico.

PROJETOS

AutoApply — ***código aberto***
github.com/gabrielchv/AutoApply

- Extensão de navegador (**Chrome MV3** e **Firefox**) que mapeia formulários de candidatura arbitrários para um perfil estruturado por meio de um **LLM**, **sem adaptadores por site**: o formulário é lido em busca de rótulos, opções e campos obrigatórios, e o modelo resolve o mapeamento.

- Projetada contra a **fabricação de informação pelo modelo**: o LLM devolve um plano de preenchimento **validado por schema, com um retry corretivo**, antes de qualquer campo ser escrito, e nenhum caminho de código envia o formulário.
- **Local-first, sem backend** — chave de API e perfil ficam no armazenamento da extensão, o currículo em PDF é processado no próprio navegador com pdf.js, e qualquer endpoint **compatível com OpenAI** funciona, inclusive um **Ollama** local; CI no **GitHub Actions** com lint, checagem de tipos, **Vitest** e os dois builds de navegador.

InquilinoIA — ***código aberto***
github.com/gabrielchv/inquilino-ia

- Assistente **RAG com citações** sobre o texto integral da Lei do Inquilinato (Lei 8.245/1991): cada afirmação precisa de **citação verbatim** do artigo, verificada em Python por substring normalizada — não na palavra do modelo.
- **Duas chamadas ao Gemini por design**: uma faz *streaming* da resposta via **SSE**, outra com **saída estruturada** extrai os pares artigo/citação para verificação — evitando o parse frágil de tags de citação dentro do stream de tokens.
- **FastAPI** e **Vue 3** num único serviço **Cloud Run**, store **Supabase pgvector**, **Terraform** para os recursos GCP e deploys sem chave via **Workload Identity Federation**.

Task Helper AI
task-organizer.gazerah.com · github.com/gabrielchv/task-organizer

- Orquestrador de tarefas em linguagem natural sobre o **Gemini 2.5 Flash**, em que o **design de prompt** converte a intenção falada em tarefas agendadas e gerenciadas.
- Detecção de **wake word** offline com um modelo **Vosk**; a transcrição é feita enviando o áudio capturado direto para a **entrada multimodal** do Gemini, em vez de manter um serviço de speech-to-text separado.
- Containerizado com **Docker** e publicado no **Google Cloud Run** com CI/CD automatizado.

HABILIDADES TÉCNICAS

Engenharia de LLMs: design de prompt, saída estruturada e interpretação de intenção, classificação com LLM, respostas em streaming em tempo real, entrada multimodal de áudio, interfaces por voz

Modelos e APIs: API Gemini, API OpenAI, TensorFlow

Fundamentos de ML *(cursos Google Cloud)***:** MLOps e plataformas de agentes, RAG, BigQuery ML, feature engineering, avaliação de modelos, IA responsável (justiça, interpretabilidade, privacidade)

Linguagens: Python, TypeScript, JavaScript, SQL

Web: React, Next.js, SvelteKit, Tailwind CSS, Node.js, FastAPI, Flask

Mobile: React Native, Expo

Cloud e DevOps: Google Cloud Platform (Cloud Run, Cloud Build, Artifact Registry), Firebase, Docker, GitHub Actions, CI/CD

Dados: BigQuery, PostgreSQL, Scrapy, BeautifulSoup

Testes: Vitest, Playwright, Storybook

Práticas: Domain-Driven Design (DDD), SOLID, Clean Architecture

FORMAÇÃO ACADÊMICA

Tecnólogo em Análise e Desenvolvimento de Sistemas
Instituto Federal de São Paulo (IFSP) · Cubatão, SP · Previsão de conclusão: Dezembro de 2026

FORMAÇÃO COMPLEMENTAR

Google Cloud Skills Boost — ***19 cursos concluídos***
2025 – 2026

Trilha Professional Machine Learning Engineer — concluída em agosto de 2026 (17 cursos e laboratórios).

Responsible AI for Developers: Fairness & Bias · Interpretability & Transparency · Privacy & Safety · Machine Learning Operations (MLOps) for Generative AI · Create Generative AI Apps on Google Cloud

Fundamentos cobertos: MLOps e plataformas de agentes, RAG (geração aumentada por recuperação), pipelines de ML, feature engineering, BigQuery ML, avaliação de modelos e práticas de IA responsável. Todos os cursos: cloudskillsboost.google/public_profiles/<id>

IDIOMAS

Português — Nativo · Inglês — Fluente